1. 概要

PhysicsNeMo を用いた車両ダイナミクスモデル構築の前段階として、車両平面運動モデル（Dynamic Bicycle Model）による車両軌跡シミュレーションを実施した。

本 PoC では、まず物理法則に基づく教師モデルを実装し、その出力を学習対象として PhysicsNeMo の MLP サロゲートモデルを構築する構成としている。

実装上は以下の 3 層に分かれる。

1. **教師物理モデル**
   Dynamic Bicycle Model と線形タイヤモデルに基づき、1 ステップ先の状態変化を計算する

2. **道路・操舵制御・軌跡生成部**
   道路中心線を生成し、操舵角を計算しながら逐次的に状態と位置を更新する

3. **PhysicsNeMo サロゲートモデル**
   教師モデルの出力を近似するニューラルネットワークを学習し、物理モデルの代替として用いる

2. 目的

本 PoC の目的は以下の通りである。

- 車両平面運動方程式とタイヤ横力モデルを用いた車両挙動の再現
- 路面摩擦係数および車速が軌跡に与える影響の確認
- PhysicsNeMo サロゲートモデル構築のための教師モデルの検証
- 将来的な高コスト物理計算の近似モデル化に向けた最小 PoC の作成

3. 全体構成

3.1 道路形状の生成

道路は以下の単純な基準経路として与える。

- 直線 100 m
- 半径 25 m の 90 度左カーブ
- 直線 100 m

コードでは曲率列 κ_t を生成し、その積分により基準経路 $(x_{ref}, y_{ref}, \psi_{ref})$ を作成している。

3.2 操舵角の計算

操舵角 δ は以下の和で与える。

- **フィードフォワード操舵**
  道路曲率から理想的な操舵角を計算する

- **フィードバック操舵**
  基準経路からの横偏差 e_y と姿勢偏差 e_ψ を用いて補正する

3.3 車両状態の更新

各時刻で車両モデルにより、以下を更新する。

- 横滑り角 β
- ヨーレート r
- 横加速度 a_y

その後に位置 (x, y)、ヨー角 ψ を更新し、軌跡を生成する。

3.4 サロゲートモデル学習

教師モデルから生成した入出力ペアを用いて、PhysicsNeMo の `FullyConnected` MLP を学習する。

学習済みサロゲートモデルは、教師モデルと同じ入力に対して近似的に状態変化を返し、逐次ロールアウトにより軌道生成にも利用できる。

4. 車両モデル

- 車両ダイナミクスは **Dynamic Bicycle Model** を使用する
- このモデルでは左右輪をまとめて前輪・後輪の 2 輪に集約し、平面内運動を近似する

4.1 状態変数

変数	意味
x, y	車両位置
ψ	ヨー角
β	横滑り角
r	ヨーレート
v_x	前進速度

4.2 入力

変数	意味
δ	操舵角
a_x	前後加速度
μ	路面摩擦係数
bank	バンク角
grade	勾配角

4.3 車両パラメータ

変数	意味
m	車両質量
I_z	ヨー慣性モーメント
l_f	重心から前輪までの距離
l_r	重心から後輪までの距離
C_f	前輪コーナリング剛性
C_r	後輪コーナリング剛性

本コードの既定値は以下である。

$$m = 1500\ \mathrm{kg}, \quad I_z = 2500\ \mathrm{kg, m^2}, \quad l_f = 1.2\ \mathrm{m}, \quad l_r = 1.6\ \mathrm{m}$$

$$C_f = C_r = 80000, \quad \Delta t = 0.1\ \mathrm{s}$$

5. 物理方程式

5.1 スリップ角

前輪・後輪のスリップ角は以下で与える。

前輪

$$\alpha_f = \delta - \beta - \frac{l_f r}{v_x}$$

後輪

$$\alpha_r = -\beta + \frac{l_r r}{v_x}$$

5.2 線形タイヤモデル

タイヤ横力は線形タイヤモデルにより

$$F_{yf}^{\mathrm{lin}} = C_f \alpha_f$$

$$F_{yr}^{\mathrm{lin}} = C_r \alpha_r$$

とする。

5.3 摩擦制限

実装では、横力は摩擦円の簡略モデルとして前後輪ごとに飽和させる。

前輪鉛直荷重

$$F_{zf} = mg\frac{l_r}{l_f + l_r}\cos(\text{grade})$$

後輪鉛直荷重

$$F_{zr} = mg\frac{l_f}{l_f + l_r}\cos(\text{grade})$$

最大横力

$$F_{yf,max} = \mu F_{zf}, \qquad F_{yr,max} = \mu F_{zr}$$

したがって実際の横力は

$$F_{yf} = \text{clip}(F_{yf}^{lin}, -F_{yf,max}, F_{yf,max})$$

$$F_{yr} = \text{clip}(F_{yr}^{lin}, -F_{yr,max}, F_{yr,max})$$

となる。

5.4 車両平面運動方程式

横方向運動

$$a_y = \frac{F_{yf} + F_{yr}}{m} - g\sin(\text{bank})$$

横滑り角の時間変化

$$\dot{\beta} = \frac{F_{yf} + F_{yr}}{mv_x} - r$$

ヨー回転

$$\dot{r} = \frac{l_f F_{yf} - l_r F_{yr}}{I_z}$$

6. 教師モデル

6.1 教師モデルの役割

教師モデルは Dynamic Bicycle Model と線形タイヤモデルに基づき、与えられた車両状態・操舵角・路面条件に対して 1 ステップ先の状態変化を計算する。

この教師モデルにより合成データを生成し、それを教師信号としてサロゲートモデルを学習する。

6.2 教師モデルの出力

改善版コードでは、教師モデルは次時刻状態そのものではなく、以下の量を出力する。

出力	意味

出力	意味
$\dot{\beta}$	横滑り角の時間変化率
$\dot{r}$	ヨーレートの時間変化率
a_y	横加速度
slip margin	横加速度余裕
slip risk	スリップ判定

この出力を用いて、状態更新は

$$\beta_{t+1} = \beta_t + \dot{\beta}_t \Delta t$$

$$r_{t+1} = r_t + \dot{r}_t \Delta t$$

により行う。

6.3 スリップ余裕（slip margin）

実装では横加速度限界を

$$a_{y,max} = \mu g \cos(\text{bank})$$

とし、余裕を

$$\text{slip margin} = 1 - \frac{|a_y|}{a_{y,max}}$$

で定義している。

- slip margin > 0：まだ余裕あり
- slip margin < 0：限界超過

6.4 スリップ判定（slip risk）

$$\text{slip risk} = \begin{cases} 1 & (\text{slip margin} < 0) \\ 0 & (\text{slip margin} \geq 0) \end{cases}$$

7. 軌跡生成

時間刻み Δt ごとに状態を更新する。

7.1 状態更新

$$\beta_{t+1} = \beta_t + \dot{\beta} \Delta t$$

$$r_{t+1} = r_t + \dot{r} \Delta t$$

$$v_{x,t+1} = v_{x,t} + a_x \Delta t$$

ヨー角はコード上では更新後のヨーレートを用いて

$$\psi_{t+1} = \psi_t + r_{t+1}\Delta t$$

としている。

7.2 進行方向

車両速度ベクトルの向きは車体姿勢 ψ と横滑り角 β の和であり、$\psi + \beta$ を有効進行方向として位置を更新する。

$$\dot{x} = v_x \cos(\psi + \beta)$$

$$\dot{y} = v_x \sin(\psi + \beta)$$

$$x_{t+1} = x_t + \dot{x}\Delta t$$

$$y_{t+1} = y_t + \dot{y}\Delta t$$

この更新を時間ステップごとに繰り返すことで、車両軌跡 (x_t, y_t) を生成する。

8. 操舵制御

8.1 フィードフォワード操舵

道路曲率 κ に対し、ホイールベース $L = l_f + l_r$ を用いて

$$\delta_{ff} = \tan^{-1}(L\kappa)$$

とする。

8.2 フィードバック操舵

基準経路に対する横偏差 e_y と姿勢偏差 e_ψ を

$$e_y = -\sin(\psi_{ref})(x - x_{ref}) + \cos(\psi_{ref})(y - y_{ref})$$

$$e_\psi = \psi - \psi_{ref}$$

として、補正操舵角を

$$\delta_{fb} = -(k_y e_y + k_\psi e_\psi)$$

とする。

最終的な操舵角は

$$\delta = \delta_{ff} + \delta_{fb}$$

であり、コードでは現実的な操舵制限として

$$-0.25 \leq \delta \leq 0.25$$

にクリップしている。

9. 初期条件

ロールアウト開始時の初期値は以下である。

$$x_0 = 0, \quad y_0 = 0, \quad \psi_0 = 0, \quad \beta_0 = 0, \quad r_0 = 0, \quad v_{x,0} = v_0$$

すなわち、初期時刻では車両は道路始点に置かれ、車体姿勢は基準経路と一致し、横滑りもヨー回転もない状態から開始する。

10. シミュレーションシナリオ

シナリオ	v_x	摩擦係数 μ
dry_slow	10 m/s	0.9
dry_nominal	12 m/s	0.9
wet_nominal	12 m/s	0.5
icy_nominal	12 m/s	0.2
icy_fast	16 m/s	0.2

すべてのシナリオでv_xは初速のまま変わらない (加速度$a_x=0)とする。

11. テスト内容

教師モデルの妥当性確認のため、以下のテストを実施している。

11.1 直進・操舵ゼロ

- 操舵ゼロ、フィードバックゼロのとき
- 車両が $y \approx 0$ を保ちながら前進することを確認

11.2 左旋回時の横方向移動

- 左カーブを与えたとき
- 最終的に y が正方向に増加することを確認

11.3 低摩擦・高速度時の逸脱増加

- dry 条件と icy_fast 条件を比較し
- 低摩擦・高速度の方が横偏差が大きくなることを確認

11.4 初期直線区間での操舵確認

- 初期直線区間では
  - フィードフォワード操舵 $= 0$
  - フィードバック操舵 $= 0$
- であることを確認

12. サロゲートモデル

PhysicsNeMo の `FullyConnected` を用いて、教師モデルの 1 ステップ出力を近似するサロゲートモデルを構築した。目的は、物理モデルを逐次直接計算する代わりに、ニューラルネットワークにより状態変化を高速に近似することである。

12.1 入力

入力は教師モデルと同じ 14 次元特徴量である。

$$(v_x, \beta, r, \delta, a_x, \mu, \text{bank}, \text{grade}, l_f, l_r, C_f, C_r, m, I_z)$$

ここで、

- v_x：前進速度
- β：横滑り角
- r：ヨーレート
- δ：操舵角
- a_x：前後加速度
- μ：摩擦係数
- $\text{bank}, \text{grade}$：道路条件
- $l_f, l_r, C_f, C_r, m, I_z$：車両パラメータ

を表す。

12.2 出力

改善版コードでは、次時刻状態そのものではなく、**状態変化率と危険度指標**を学習対象とした。

$$(\dot{\beta}, \dot{r}, a_y, \text{slip margin}, \text{slip risk}_{\text{l}}\text{ogit})$$

このうち、

- $\dot{\beta}$：横滑り角の時間変化率
- $\dot{r}$：ヨーレートの時間変化率
- a_y：横加速度
- slip margin：横加速度限界に対する余裕
- $\text{slip risk}_{\text{l}}\text{ogit}$：スリップ判定のロジット出力

である。

状態更新時には、ネットワーク出力された $\dot{\beta}, \dot{r}$ を用いて

$$\beta_{t+1} = \beta_t + \dot{\beta}_t \Delta t$$

$$r_{t+1} = r_t + \dot{r}_t \Delta t$$

と積分して次時刻状態を得る。

このように **微分量を学習する構成**とすることで、物理式との対応が取りやすく、状態量そのものを直接回帰するよりも安定した学習を狙っている。

12.3 ネットワーク構成

サロゲートモデルは PhysicsNeMo の `FullyConnected` を利用した多層パーセプトロンとした。入力 14 次元に対し、隠れ層を複数段持ち、出力 5 次元を返す構成である。

本 PoC では、まず CPU 上で学習可能な比較的小規模な MLP を用い、教師モデルの 1 ステップ写像を近似する最小構成を採用した。

12.4 学習データの生成

学習データは実測データではなく、教師物理モデルから合成生成した。入力特徴量は単純な一様サンプリングではなく、以下のような**混合分布**で生成した。

- **通常領域**：中程度の速度、高めの摩擦係数、小さめの操舵角
- **限界近傍領域**：やや高速度、低摩擦、大きめの操舵角
- **ストレス領域**：高速度、低摩擦、やや大きい横滑り角・ヨーレート

このようにすることで、通常走行だけでなく、**逸脱やスリップが起こりやすい条件**も学習データに十分含めるようにした。

また、教師モデルにより各入力に対する

- $\dot{\beta}$
- $\dot{r}$
- a_y
- slip margin
- slip risk

を計算し、教師ラベルとして用いた。

12.5 標準化

入力変数には速度・角度・車両質量・コーナリング剛性など、スケールの大きく異なる量が含まれる。そのため、学習前に訓練データから平均と標準偏差を求め、**入力および回帰出力を標準化**した。

これにより、

- 学習の安定化
- 勾配の極端な偏りの抑制
- 異なる物理量を同時に扱う際の収束性改善

を図っている。

なお、slip risk は分類タスクであるため、0/1 ラベルをそのまま用い、ロジット出力に対して分類損失を計算している。

12.6 損失関数

学習では、以下の損失の和を用いた。

1. **回帰損失**
   教師モデル出力との平均二乗誤差（MSE）

2. **分類損失**
   スリップ判定に対する `BCEWithLogitsLoss`

3. **物理整合損失**
   サロゲートが出力した $\dot{\beta}, \dot{r}, a_y, \text{slip margin}$ が、車両平面運動方程式と摩擦制限から計算される値と大きく乖離しないようにする損失

損失の考え方としては、**教師モデルへの追従**と**物理的な一貫性**の両方を満たすことを目指している。

概念的には、

$$L = L_{reg} + \lambda_{cls} L_{cls} + \lambda_{phys} L_{phys}$$

であり、

- L_{reg}：$\dot{\beta}, \dot{r}, a_y, \text{slip margin}$ の MSE
- L_{cls}：slip risk の BCE
- L_{phys}：物理整合損失

である。

12.7 データ分割と評価

学習データは以下に分割した。

- 訓練用データ
- 検証用データ
- テスト用データ

これにより、学習中は検証データで性能を監視し、最終的には未使用のテストデータで 1 ステップ予測性能を確認する構成とした。

また、1 ステップ予測だけでなく、学習済みサロゲートを用いた**逐次ロールアウト**も実施し、

- 軌跡形状
- 横偏差の増え方
- 低摩擦時の逸脱傾向
- スリップ危険度の増加傾向

が教師モデルと整合するかを確認した。

12.8 ロールアウト時の使い方

学習済みサロゲートをロールアウトに用いる際には、各時刻で

1. 現在状態と入力から特徴量を作る
2. サロゲートが $\dot{\beta}, \dot{r}, a_y, \text{slip margin}$ を予測する
3. β, r を時間積分して次時刻状態を求める
4. ψ, x, y を更新する

という流れで教師モデルと同様に軌跡を生成する。

すなわち、1 ステップ近似器を逐次的に繰り返し適用することで、サロゲート単体で軌道生成を行う構成である。

13. 結果

13.1 教師モデルの軌跡

以下の図は各シナリオにおける教師モデルの車両軌跡を示す。

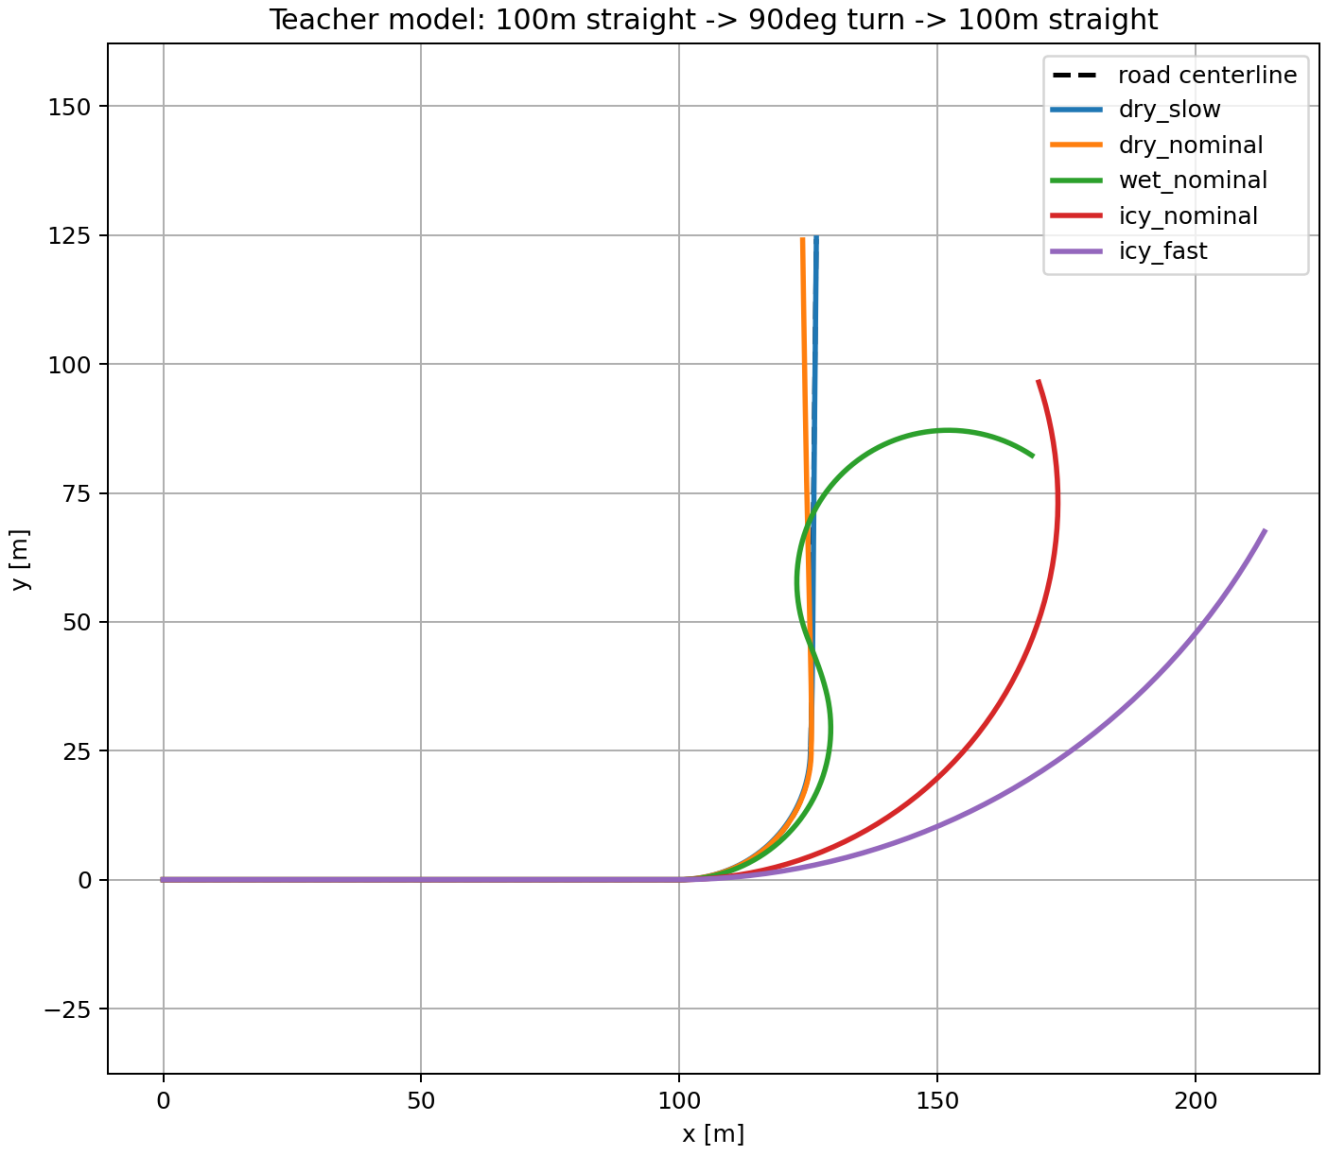

確認された傾向は以下の通りである。

- dry 条件では道路形状にほぼ追従する
- wet 条件ではカーブ外側へ膨らむ
- icy 条件では大きく外側へ逸脱する
- 高速かつ低摩擦条件ではカーブを維持できない

この傾向は、必要横力と最大発生横力の関係から説明できる。

カーブ走行に必要な横力は

$$F = \frac{mv^2}{R}$$

一方、タイヤが発生できる最大横力は概ね

$$F_{max} = \mu F_z$$

である。したがって

$$\frac{mv^2}{R} > \mu F_z$$

となると、必要な向心力をタイヤが発生できず、車両はカーブ外側へ逸脱しやすくなる。

13.2 サロゲートモデルの軌跡

学習済みサロゲートモデルに対しても、教師モデルと同じシナリオ条件でロールアウトを実施した。その結果、サロゲートモデルでも以下の傾向が再現された。

- dry 条件では基準道路に概ね追従する
- wet 条件では外側への膨らみが増加する
- icy 条件では逸脱がさらに大きくなる
- low-μ かつ高速度条件では、教師モデル同様に追従性が大きく悪化する

以下の図はサロゲートモデルによる軌跡例である。

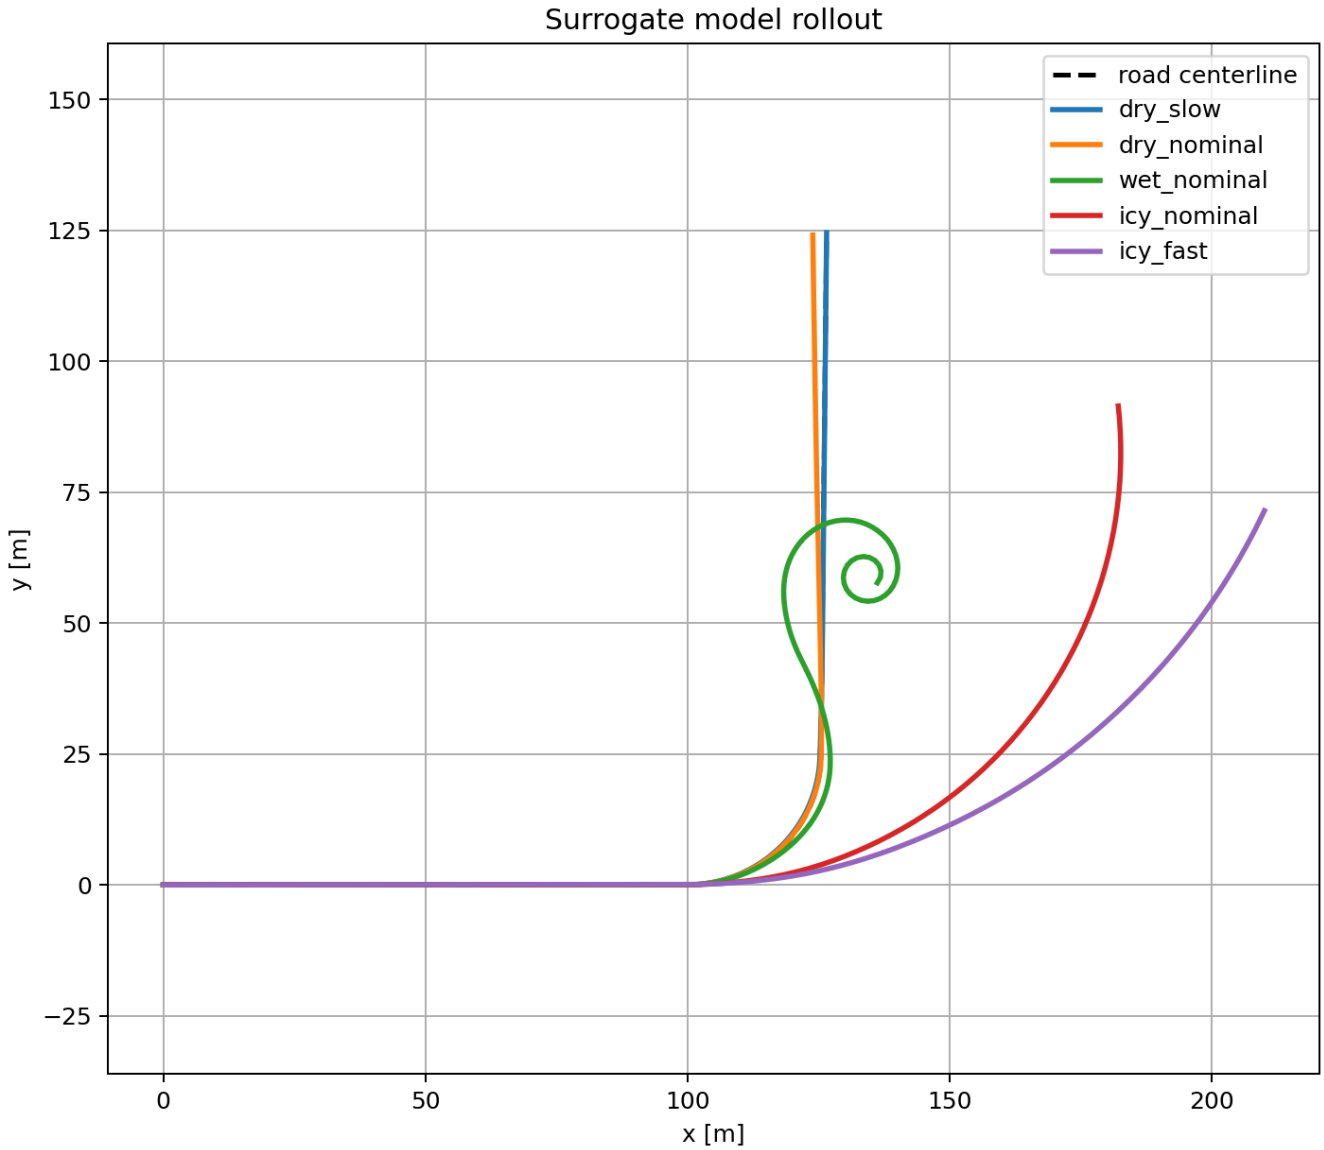

サロゲートの軌跡は教師モデルと完全一致するわけではないが、シナリオ間の相対的な挙動差は概ね再現できた。特に、低摩擦・高速度条件ほど軌道逸脱が大きくなるという傾向が保たれており、教師物理モデルの代替として一定の妥当性が確認できた。

13.3 教師モデルとサロゲートモデルの比較

え
今回の結果から、サロゲートモデルは以下の意味で有効であると考えられる。

- 1 ステップの状態変化率を概ね近似できる
- 逐次ロールアウトしても大きく不自然な軌道にはなっていない
- 路面摩擦係数や車速の違いによる挙動差を保持できている
- 危険条件での逸脱傾向を定性的に再現できている

一方で、ロールアウトでは小さな 1 ステップ誤差が逐次蓄積するため、

- カーブ出口付近で教師モデルとの差が広がる
- 低摩擦条件で誤差が増幅されやすい
- スリップ危険度の閾値近傍で判定差が出る可能性がある

といった点には注意が必要である。したがって、サロゲート性能の評価には 1 ステップ誤差だけでなく、ロールアウトベースの軌跡比較も重要である。

14. この PoC で確認したこと

本 PoC で確認したポイントは以下である。

- Dynamic Bicycle Model により、摩擦係数と速度の違いによる軌跡差を再現できる
- 低摩擦・高速条件ほど横加速度限界に達しやすい
- 教師モデルとして妥当な挙動を簡単なテストで確認できた
- 教師モデルから生成した合成データを用いて PhysicsNeMo サロゲートを学習できた
- サロゲートモデルでも、dry / wet / icy の相対的な挙動差を概ね再現できた
- サロゲートを逐次適用することで、教師モデルに近い軌道生成が可能であることを確認した

15. Alpamayo + PhysicsNeMo 学習アーキテクチャ案

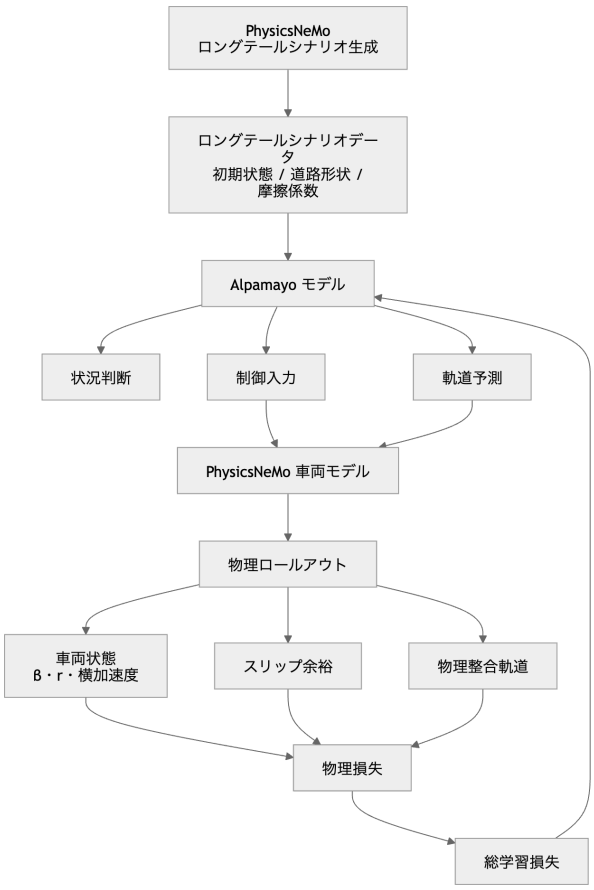

PhysicsNeMo を以下の2つの役割で利用する。

- **ロングテールシナリオ生成器**
- **物理評価モデル（Physics Critic）**

これにより、Alpamayo が生成する判断・制御・軌道が
車両ダイナミクスに照らして物理的に妥当かどうかを評価しながら学習を行う。

15.1 ロングテールシナリオ生成

PhysicsNeMo を用いて、車両ダイナミクスモデルに基づくシミュレーションを実行し、物理的に危険な挙動が発生しやすい条件を探索する。

具体的には、以下のようなパラメータを変化させながら車両挙動をシミュレーションする。

- 路面摩擦係数（乾燥路面・雨・雪・氷）
- 初期速度
- 道路曲率（カーブ半径）
- 勾配
- バンク角

各条件に対して PhysicsNeMo により車両運動を計算し、

- 横加速度
- ヨーレート
- スリップ余裕（slip margin）

などの指標を評価する。

これらの物理指標が危険領域に近づく条件を抽出することで、通常の走行データでは出現頻度の低いロングテールシナリオを生成する。

15.2 Alpamayo 推論

生成されたシナリオを入力として Alpamayo は以下を出力する。

- **状況判断**
- **車両制御（操舵・加減速）**
- **将来軌道予測**

15.3 物理ロールアウト

Alpamayoの車両制御の出力をPhysicsNeMoの車両モデルに入力し車両ダイナミクスに基づく状態遷移を計算する。

PhysicsNeMo により以下の物理状態が得られる。

- 横滑り角
- ヨーレート
- 横加速度
- スリップ余裕
- 物理整合軌道

15.4 物理評価

PhysicsNeMo の結果を用いて、Alpamayo の出力を評価する。

主な評価項目は以下である。

- 車両ダイナミクスとの整合性
- 横加速度限界
- スリップリスク
- 軌道の物理的妥当性

15.5 学習更新

物理評価から計算された損失をAlpamayo の学習損失に組み込みモデルを更新する。

これにより Alpamayo は 物理的に危険な制御やスリップを引き起こす軌道
を避ける方向に学習される。

15.6　物理ガードレールとしての利用

PhysicsNeMoは教師データではなく、物理ガードレール（Physics Critic）として用い、Alpamayo の出力が、車両ダイナミクス、摩擦限界、スリップ条件と矛盾しないように制約を与える。つまり PhysicsNeMo は正解軌道を与えるのではなく物理的に危険な挙動を罰する役割を担う。

15.7 期待される効果

本アーキテクチャにより以下の効果が期待される。

- 車両運動限界に対する理解の向上
- スリップなどの危険挙動の抑制
- ロングテールシナリオへの対応能力向上
- 判断と物理整合の改善

16. 今後の展開

今後は以下を検討する。

- 制御入力や道路条件の多様化
- フルカーモデルやより高忠実度なタイヤモデルへの拡張
- 他のリスク条件（ヨー不安定化、軌道逸脱、横転リスクなど）の追加
- ロングテールシナリオ生成による危険挙動学習
- 実データあるいは高忠実度シミュレータとの接続